

9기_DL팀_허정인_요약본

#5.0 토큰화 개요

토큰화: 자연어 처리 모델을 만들기 위해 말뭉치를 토큰으로 나누어야 함

#5.1 단어 및 글자 토큰화

- 단어 토큰화: 텍스트 데이터를 의미 있는 단위인 단어로 분리하는 작업
 - 자연어 처리 분야에서 핵심적인 전처리 작업 중 하나
 - 품사 태깅, 개체명 인식, 기계 번역 등의 작업에서 널리 사용됨
 - 가장 일반적인 토큰화 방법
- 글자 토큰화: 글자 단위로 문장을 나누는 방식
 - 비교적 작은 단어 사전을 구축할 수 있다는 장점
 - 컴퓨터 자원의 효율적 사용 가능, 각 단어를 더 자주 학습할 수 있음
- 자모 라이브러리 활용
- 단점: 개별 토큰의 의미가 없으므로 자연어 모델이 각 토큰의 의미를 조합해 결과를 도출해야 함

#5.2 형태소 토큰화

- 형태소 토큰화: 텍스트를 형태소 단위로 나누는 토큰화 방법
- 형태소 어휘 사전: 자연어 처리에서 사용되는 단어의 집합인 어휘 사전 중, 각 단어의 형태소 정보를 포함하는 사전
- KoNLPy: 한국어 자연어 처리를 위해 개발된 라이브러리
 - Okt: 문장을 입력 받아 명사, 구, 형태소, 품사 등의 정보 추출하는 메서드 제공
 - 꼬꼬마: 명사, 문장, 형태소, 품사 추출
 - 동일한 메서드라도 분석기에 따라 다른 결과 도출
- NLTK: 자연어 처리를 위해 개발된 라이브러리
 - 토큰화, 형태소 분석, 구문 분석, 개체명 인식, 감성 분석 등과 같은 기능 제공
 - 주로 영어 자연어 처리를 위해 개발 but 다양한 언어 지원

- spaCy: 사이썬을 기반으로 개발된 오픈 소스 라이브러리
 - 빠른 속도와 높은 정확도를 목표로 하는 머신 러닝 기반의 자연어 처리 라이브러리

#5.3 하위 단어 토큰화

- 아이디어: 너무 미세하지도, 너무 거칠지도 않게 중간 단위로 분해
- 장점: OOV 감소, 어휘축소, 형태변형 대응
- 원칙: 자주 함께 나타나는 문자열을 묶어 서브워드 단위로 모델링
- BPE: (1) 문자 단위 시작 → (2) 가장 자주 출현하는 인접 쌍 병합 반복
- SentencePiece 라이브러리: 구글에서 개발한 오픈소스 하위 단어 토크나이저 라이브러리
- Korpora 라이브러리: 한국어 공개 코퍼스 수집 패키지
- 토크나이저 학습 공통 프로세스: 데이터 수집 → 정규화 → 프리토큰화 → 모델 학습 → 포스트프로세싱 → 평가 → 저장/배포
- WordPiece: BERT 계열에서 채택, 확률기반 최대우도 기준으로 어휘 선정
- Hugging Face tokenizers 라이브러리 사용 → 대용량 코퍼스에서 빠른 학습, 트랜스포머 호환
- WordPiece 토크나이저 모델 학습 과정: 코퍼스 수집정제 → 정규화 규칙 확정 → 프리토큰화 → WordPiece 학습 → 포스트프로세싱 → 품질평가 → 버전관리 및 배포

#6.0 임베딩 개요

- 텍스트 벡터화: 텍스트를 숫자로 변화하는 과정
- 워드 임베딩: 단어를 고정된 길이의 실수 벡터로 표현하는 방법

#6.1 언어 모델

- 언어 모델: 입력된 문장으로 각 문장을 생성할 수 있는 확률을 계산하는 모델
 - 자기회귀 언어 모델: 입력된 문장들의 조건부 확률을 이용해 다음에 올 단어 예측
 - 통계적 언어 모델: 언어의 통계적 구조를 이용해 문장이나 단어의 시퀀스를 생성하거나 분석

#6.2 N-gram

- 가장 기초적인 통계적인 언어 모델

- 텍스트에서 N개의 연속된 단어 시퀀스를 하나의 단어로 취급 → 특정 단어 시퀀스가 등장할 확률 추정

#6.3 TF-IDF

- 텍스트 문서에서 특정 단어의 중요도를 계산하는 방법
 - 문서 내에서 단어의 중요도를 평가하는 데 사용되는 통계적 가중치
 - Bow에 가중치를 부여하는 방법
- 단어 빈도: 문서 내에서 특정 단어의 빈도수를 나타내는 값
- 문서 빈도: 한 단어가 얼마나 많은 문서에 나타나는 값
- 열문서 빈도: 문서 내에서 특정 단어가 얼마나 중요한지에 대한 값