


[딥러닝 파이토치 교과서] 4장

4.1 인공 신경망의 한계와 딥러닝 출현

- 퍼셉트론
 - 오늘날 신경망(딥러닝)의 기원이 되는 알고리즘
 - 다수의 신호를 입력으로 받아 하나의 신호를 출력해 정보를 앞으로 전달



- 논리 게이트
 - AND 게이트

x_1	x_2	y
0	0	0
1	0	0
0	1	0
1	1	1

모든 입력이 1일 때 작동

- OR 게이트

x_1	x_2	y
0	0	0
1	0	1
0	1	1
1	1	1

입력 모두가 0을 갖는 경우를 제외한 나머지 경우 모두 작동

◦ XOR 게이트


x_1	x_2	y
0	0	0
1	0	1
0	1	1
1	1	0

입력 두 개 중 한 개만 1일 때 작동

- 데이터가 비선형적으로 분리되어 제대로 된 분리가 어려움
→ 단층 퍼셉트론에서 학습이 불가능함
- 이를 해결하기 위해 입력층과 출력층 사이 하나 이상의 중간층을 두는 다층 퍼셉트론 방식을 고안
→ 이때 입력층과 출력층 사이 은닉층이 여러 개 있는 신경망을 **심층 신경망(딥러닝)**이라 함

4.2 딥러닝 구조

4.2.1 딥러닝 용어



구분	구성 요소	설명
층	입력층(input layer)	데이터를 받아들이는 층
	은닉층(hidden layer)	모든 입력 노드부터 입력 값을 받아 가중합을 계산하고, 이 값을 활성화 함수에 적용하여 출력층에 전달하는 층
	출력층(output layer)	신경망의 최종 결괏값이 포함된 층

구분	구성 요소	설명
가중치(weight)		노드와 노드 간 연결 강도
바이어스(bias)		가중합에 더해 주는 상수로, 하나의 뉴런에서 활성화 함수를 거쳐 최종적으로 출력되는 값을 조절하는 역할을 함
가중합(weighted sum), 전달 함수		가중치와 신호의 곱을 합한 것
함수	활성화 함수(activation function)	신호를 입력받아 이를 적절히 처리하여 출력해 주는 함수
	손실 함수(loss function)	가중치 학습을 위해 출력 함수의 결과와 실제 값 간의 오차를 측정하는 함수

가중치

- 입력 값이 연산 결과에 미치는 영향력을 조절하는 요소

가중합(전달 함수)

- 각 노드에서 들어오는 신호에 가중치를 곱해 다음 노드로 전달하는 값을 모두 더한 합계
- 노드의 가중합이 계산되면 이를 활성화 함수로 보내기 때문에 전달 함수라고도 함
- 가중합을 구하는 공식


$$\sum_i w_i x_i + b$$

(w : 가중치, b : 바이어스)


활성화 함수

- 전달 함수에서 전달받은 값을 출력할 때, 일정 기준에 따라 출력 값을 변화시키는 비선형 함수
- 여러 활성화 함수
 - 시그모이드 함수

$$f(x) = \frac{1}{1 + e^{-x}}$$




- 선형 함수의 결과를 0과 1 사이에서 비선형 형태로 변형
- 주로 로지스틱 회귀와 같은 분류 문제를 확률적으로 표현하는 데 사용
- 기울기 소멸 문제로 인해 현재 딥러닝 모델에서는 잘 사용하지 않음
- 하이퍼볼릭 탄젠트 함수




- 선형 함수의 결과를 -1과 1 사이에서 비선형 형태로 변형
- 시그모이드에서 결괏값의 평균이 0이 아닌 양수로 편향된 문제 해결, 여전히 기울기 소멸 문제 발생

○ 렐루 함수



- 입력이 음수일 때 0 출력, 양수일 때 입력 그대로 출력
- 경사 하강법에 영향을 주지 않아 학습 속도가 빠름(하이퍼볼릭 탄젠트 함수 대비 6배 빠름)
- 기울기 소멸 문제 발생하지 않음
- 은닉층에서 주로 사용됨
- 음수 값을 입력받으면 0을 출력하기 때문에 학습 능력이 감소하는 문제 발생
→ 해결을 위해 리키 렐루 함수 등 사용

○ 리키 렐루 함수



- 입력 값이 음수이면 0이 아닌 0.001과 같은 매우 작은 수를 반환
- 입력 값이 수렴하는 구간이 제거되어 렐루 함수 함수를 사용할 때의 문제를 해결 가능

○ 소프트맥스 함수

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

- 입력 값을 0에서 1 사이 출력되도록 정규화하여 출력 값들의 총합이 항상 10이 되도록 함
- 딥러닝에서 출력 노드의 활성화 함수로 많이 사용됨

손실 함수

- cf. 경사하강법
 - 학습률과 손실 함수의 순간 기울기를 이용해 가중치 업데이트
 - 미분의 기울기를 이용해 오차를 비교하고 최소화
→ 이때 오차를 구하는 방법이 손실 함수!
- 정의
 - 학습을 통해 얻은 데이터의 추정치가 실제 데이터와 얼마나 차이 나는지 평가하는 지표
→ 값이 클수록 많이 틀림
- 여러 손실 함수
 - 평균 제곱 오차
 - 실제 값과 예측 값의 차이를 제곱해 평균을 낸 것
 - 값이 작을 수록 예측력이 좋음
 - 회귀에서 주로 사용됨
 - 수식

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

- 크로스 엔트로피 오차
 - 분류 문제에서 원-핫 인코딩 했을 때에만 사용할 수 있는 오차 계산법
 - 시그모이드 함수에서 평균 제곱 오차를 적용하면 자연 상수 e 때문에 매끄럽지 못한 그래프가 출력되기 때문에 사용


- 경사 하강법 과정에서 학습이 지역 최소점에서 멈추는 것을 방지하기 위해 자연 로그를 모델의 출력 값에 취함

$$CrossEntropy = - \sum_{i=1}^n y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

4.2.2 딥러닝 학습

- 딥러닝 학습의 두 단계



○ 1단계: 순전파

- 네트워크에 훈련 데이터가 들어올 때 발생
- 데이터를 기반으로 예측 값을 계산하기 위해 전체 신경망을 교차해 지나감
- 이전 층의 뉴런에서 수신한 정보에 변환을 적용해 다음(은닉) 층의 뉴런으로 전송
- 네트워크를 통해 입력 데이터 전달


○ 2단계: 역전파

- 손실 함수로 네트워크의 오차(예측 값과 실제 값의 차이)를 측정


- 이상적인 손실 함수 비용인 0에 가깝도록 훈련을 반복하며 가중치 조정
- 손실(오차)가 계산되면 정보가 출력층 → 은닉층 → 입력층 즉, 역으로 전파됨
- 이렇게 계산한 각 뉴런의 결과를 또다시 순전파의 가중치 값으로 사용

4.2.3 딥러닝의 문제점과 해결 방안

- 은닉층이 많을 수록 데이터 분류가 잘 되지만, 다음 세 가지 문제가 발생 가능함
 - 과적합 문제
 - 훈련 데이터를 과하게 학습해서 발생
 - 훈련 데이터 오차는 감소하지만, 검증 데이터에 대해서는 오차 증가
 - 해결을 위해 임의로 일부 노드들을 학습에서 제외시키는 드롭아웃이 있음





일반적인 신경망



드롭아웃이 적용된 신경망


- 기울기 소멸 문제
 - 출력층에서 은닉층으로 전달되는 오차가 크게 줄어 학습이 되지 않는 현상
 - 기울기 소멸로 학습되는 양이 0에 가까워져 학습이 더디게 진행되다 오차를 줄이지 못하고 그대로 수렴됨
 - 은닉층이 많은 신경망에서 주로 발생
 - 시그모이드/하이퍼볼릭 탄젠트를 렐루 활성화 함수로 대체하여 해결 가능



◦ 성능 감소 문제

- 손실 함수의 비용이 최소가 되는 지점을 찾기 위해 기울기가 낮은 쪽으로 이동하는 과정을 반복
 - 성능이 나빠질 수 있음
- 해결을 위해 확률적 경사 하강법과 미니 배치 경사 하강법 사용

cf) 경사 하강법



- 배치 경사 하강법
 - 전체 데이터셋에 대한 오류를 구한 뒤 기울기를 한 번만 계산해 모델의 파라미터 업데이트
 - 전체 훈련 데이터셋에 대해 가중치 편미분
 - 한 스텝에 모든 훈련 데이터셋을 사용해 학습이 오래 걸린다는 단점 → 확률적 경사 하강법 사용
- 확률적 경사 하강법
 - 임의로 선택한 데이터에 대해 기울기 계산 → 적은 데이터를 사용해 빠른 계산 가능
 - 다만 파라미터 변경 폭이 불안정하고, 때로 배치 경사 하강법보다 정확도가 낮음
- 미니 배치 경사 하강법
 - 전체 데이터셋을 미니 배치 여러 개로 나눔
→ 미니 배치 한 개마다 기울기를 구해 평균 기울기로 모델 업데이트 해 학습

4.2.4 딥러닝을 사용할 때 이점


- 특성 추출
 - 사람이 인지하는 데이터를 컴퓨터가 인지할 수 있는 데이터로 변환할 때, 데이터 별 특징을 찾아내고 이를 토대로 데이터를 벡터로 변환하는 작업

- 딥러닝에서는 은닉층을 깊게 쌓는 방식으로 파라미터를 늘려 특성 추출 과정을 알고리즘에 통합시킴
- 빅데이터의 효율적 활용
 - 딥러닝에서 특성 추출을 알고리즘에 통합시킬 수 있는 것은 빅데이터 덕분
 - 딥러닝을 학습에 이용한 특성 추출은 데이터 사례가 많을 수록 성능이 향상되기 때문
 - 확보한 데이터가 적다면 딥러닝의 성능을 기대하기 어렵다는 뜻이기도 함

4.3 딥러닝 알고리즘

4.3.1 심층 신경망(DNN)


- 정리



- 입력층과 출력층 사이 다수의 은닉층을 포함하는 인공 신경망
- 다수의 은닉층을 추가해 별도의 트릭 없이 비선형 분류 가능
- 장점 - 다양한 비선형적 관계 학습 가능
- 단점 - 학습을 위한 연산량 많음, 기울기 소멸 문제 발생 가능
 - 해결을 위해 드롭아웃, 렐루 함수, 배치 정규화 등 적용

4.3.2 합성곱 신경망(CNN)


- 정리



- 합성곱층과 풀링층을 포함
- 이미지 처리 성능이 좋은 인공 신경망 알고리즘
→ 특히 객체, 얼굴, 장면을 인식하기 위한 패턴을 찾는 데 특히 유용
- 대표적으로 LetNet-5, AlexNet이 있음
- 층을 더 깊게 쌓은 신경망으로 VGG, GoogLeNet, ResNet 등이 있음

4.3.3 순환 신경망(RNN)

- 정리




- 시계열 데이터 같은 시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망
- 순환은 자기 자신을 참조한다는 뜻으로, 현재 결과가 이전 결과와 연관이 있음
- 특징
 - 시간성을 가진 데이터가 많음
 - 시간성 정보를 이용해 데이터의 특징을 잘 다룸

- 데이터가 동적이고, 길이가 가변적임
- 매우 긴 데이터를 처리하는 연구가 활발히 진행되고 있음
- 기울기 소멸 문제로 학습이 제대로 되지 않는다는 문제가 있음
 - 해결을 위해 메모리 개념을 도입한 LSTM이 사용됨
- 자연어 처리 분야와 궁합이 맞음

4.3.4 제한된 볼츠만 머신(RBM)

- 정리



- 볼츠만 머신 - 가시층과 은닉층으로 구성된 모델
- 가시층은 은닉층과만 연결되는 볼츠만 머신을 제한된 볼츠만 머신이라고 함
- 특징
 - 차원 감소, 분류, 선형 회귀 분석, 협업 필터링, 특성 값 학습, 주제 모델링에 사용
 - 기울기 소멸 문제 해결을 위한 사전 학습 용도로 활용 가능
 - 심층 신뢰 신경망의 요소로 활용됨

4.3.5 심층 신뢰 신경망(DNN)


- 정리

- 사전 훈련된 제한된 볼츠만 머신을 층층이 쌓아 올린 신경망
- 레이블이 없는 데이터에 대한 비지도 학습 가능
- 부분적인 이미지에서 전체를 연상하는 일반화와 추상화 과정을 구현할 때 유용

- 학습 절차

1. 가시층과 은닉층 1에 제한된 볼츠만 머신을 사전 훈련합니다.
2. 첫 번째 층 입력 데이터와 파라미터를 고정하여 두 번째 층 제한된 볼츠만 머신을 사전 훈련합니다.
3. 원하는 층 개수만큼 제한된 볼츠만 머신을 쌓아 올려 전체 DBN을 완성합니다.

▼ 그림 4-28 심층 신뢰 신경망



- 특징

- 순차적으로 학습하며 계층적 구조 생성
- 비지도 학습으로 학습
- 위로 올라갈 수록 추상적 특성 추출
- 학습된 가중치를 다층 퍼셉트론의 가중치 초기값으로 사용