

5.3 전이 학습 (Transfer Learning)

1. 전이 학습의 필요성

- 딥러닝 모델은 일반적으로 대규모 데이터셋과 막대한 연산 자원을 요구합니다.
- 예를 들어, ImageNet(천만 장 이상의 이미지, 1000개 이상의 클래스) 같은 데이터셋은 대기업 연구소나 대규모 연구팀이 아니면 직접 학습하기 어렵습니다.
- 하지만 실제 현업 문제에서는 데이터셋이 작고, 라벨링 비용도 높습니다.
- 따라서, **이미 학습된 모델의 지식을 새로운 문제에 전이(transfer)**시켜 사용하는 방식이 필요합니다. 이것이 전이 학습입니다.

2. 전이 학습의 기본 개념

- 사전 훈련된(pre-trained) 모델: 대규모 데이터셋에서 학습된 모델 (예: ResNet, VGG, Inception, MobileNet)
- 새로운 과제: 작은 데이터셋으로 학습해야 하는 문제 (예: 의료 영상에서 암 진단, 특정 제품 분류 등)
- 전이 학습은 사전 학습된 모델의 가중치를 가져와서 일부를 재활용하고, 필요한 부분만 조정하는 전략입니다.

핵심 효과:

1. 데이터가 적어도 좋은 성능을 냄
2. 학습 속도가 훨씬 빠름
3. 일반화 성능이 개선됨

3. 특성 추출 기법 (Feature Extraction)

- 정의: 사전 훈련된 모델에서 합성곱층은 그대로 두고, 마지막 분류기(FC층)만 교체하여 학습
- 원리:
 - 합성곱층은 이미지의 일반적 특징(선, 모서리, 패턴)을 학습해두었으므로

그대로 활용

- 데이터셋마다 달라지는 것은 클래스(label)의 종류이므로, 마지막 FC층만 새롭게 학습
- 장점: 빠르고, 작은 데이터셋에서도 과적합을 줄일 수 있음
- 구조:
 - Feature Extractor (합성곱층): 가중치 고정
 - Classifier (FC층): 새롭게 학습

대표 모델들:

- Xception, Inception V3, ResNet50, VGG16/19, MobileNet 등

4. ResNet (Residual Network)

- Residual Block 구조 도입 → 기울기 소실(vanishing gradient) 문제를 완화
- 깊은 네트워크도 안정적으로 학습 가능
- ResNet18, ResNet34, ResNet50, ResNet101 등으로 나뉨
- 예: ResNet50은 50개 층으로 구성된 CNN

단점:

- 입력 제약이 크고, 메모리 사용량이 많으며, 학습 속도가 느릴 수 있음

5. PyTorch 텐서 관련 함수 비교

함수	메모리	그래프 연결 여부	특징
clone()	새 메모리 할당	계산 그래프에 남음	값만 복사, 학습 추적 O
detach()	메모리 공유	그래프 연결 끊김	새로운 학습에는 사용 불가
clone().detach()	새 메모리 할당	그래프 연결 끊김	완전히 독립된 텐서 생성

6. 미세 조정 기법 (Fine-tuning)

- 정의: 특성 추출에서 나아가, 합성곱층까지 포함하여 일부 또는 전체 가중치를 다시 학습시키는 방법
- 필요성: 데이터셋이 크거나, 기존 데이터셋과 성격이 크게 다를 때
- 방법:
 - 사전 학습된 네트워크의 일부 층을 unfreeze 하여 재학습
 - 과적합 방지를 위해 learning rate 조절 필요

데이터셋 크기와 유사성에 따른 전략:

1. 데이터셋 크고, 유사성 작음 → 모델 전체 재학습
2. 데이터셋 크고, 유사성 큼 → 합성곱층 뒷부분 + 분류기 학습
3. 데이터셋 작고, 유사성 작음 → 합성곱층 일부 + 분류기 학습 (효과 제한적)
4. 데이터셋 작고, 유사성 큼 → 분류기만 학습 (합성곱층 고정, 과적합 방지)

5.4 설명 가능한 CNN (Explainable CNN)

1. 필요성

- CNN은 강력하지만, 내부 작동을 사람이 이해하기 어렵습니다. → “블랙박스 모델”
- 의료, 금융, 자율주행 등에서는 왜 이런 결론이 나왔는지 설명 가능성이 필수
- 따라서 CNN의 내부 과정을 시각화하고 설명하는 연구가 활발히 진행됩니다.

2. 특성 맵 시각화 (Feature Map Visualization)

- 특성 맵(feature map): 합성곱 필터가 입력에 적용된 결과
- 층이 깊어질수록 원래 이미지와 닮은 꼴은 사라지고, **고수준 특성(모양, 질감, 패턴)**만 남음
- 시각화를 통해 “CNN이 어떤 부분을 중점적으로 보았는가”를 확인 가능
- 신뢰성 향상, 모델 디버깅에도 활용

5.5 그래프 합성곱 네트워크 (Graph Convolutional Network, GCN)

1. 그래프란?

- 노드(node): 개체 (사람, 논문, 제품 등)
- 에지(edge): 노드 간의 관계 (친구 관계, 인용 관계, 거래 관계 등)
- 그래프는 방향성이 있거나 없을 수 있음

예시:

- SNS: 사용자(노드) + 친구 관계(에지)
- 논문 인용 네트워크: 논문(노드) + 인용(에지)

2. 그래프 신경망 (GNN)

- 그래프 구조 데이터를 다룰 수 있는 신경망 구조
- 일반 신경망은 행렬/텐서를 입력받지만, GNN은 **인접 행렬(Adjacency Matrix)**과 **특성 행렬(Feature Matrix)**을 함께 사용

과정:

1. 인접 행렬 (Adjacency Matrix)

- n개의 노드 관계를 $n \times n$ 행렬로 표현
- $A_{ij}=1$ 또는 $A_{ij}=0$ → 노드 i와 j 연결됨
- $A_{ij}=0$ 또는 $A_{ij}=1$ → 연결 없음

2. 특성 행렬 (Feature Matrix)

- 각 노드의 속성을 행으로 표현
- 예: SNS라면 사용자 나이, 성별, 관심사 등의 벡터

3. 그래프 합성곱 네트워크 (GCN)

- 합성곱 연산을 그래프 데이터에 확장

- 핵심 아이디어: **이웃 노드들의 특성을 집계(aggregate)**하여 새로운 특성을 만든다.
- CNN이 픽셀 주변 정보를 활용하는 것처럼, GCN은 노드 주변 이웃 정보를 활용

구조:

- 그래프 합성곱층: 노드 특성 + 이웃 노드 특성 → 새로운 노드 특성
- 여러 층을 쌓으면 더 넓은 이웃까지 고려 가능

4. 리드아웃(Readout)

- 그래프 전체를 하나의 벡터로 표현하는 단계
- 모든 노드의 특성을 평균/합산하여 하나의 글로벌 벡터 생성
- 그래프 분류, 전체 예측 등에 활용

5. GCN 활용

- SNS 분석: 사용자 관계 기반 추천, 커뮤니티 탐지
- 논문 인용 네트워크: 연구 분야 클러스터링, 추천 시스템
- 3D Mesh 분석: 표면 구조 분석
- 분자 구조 분석: 분자의 원자(노드)와 결합(에지)을 그래프로 보고, 신약 개발에 활용

최종 요약

1. 전이 학습

- 대규모 데이터셋으로 학습된 모델을 새로운 문제에 맞게 활용
- 특성 추출: 합성곱층 고정, 분류기만 학습
- 미세 조정: 합성곱층까지 일부/전체 업데이트

2. 설명 가능한 CNN

- CNN의 내부 과정을 시각적으로 설명

- 특성 맵 시각화: 어떤 부분을 강조했는지 확인 가능 → 신뢰성 확보

3. 그래프 합성곱 네트워크

- 그래프 데이터(노드+에지)를 처리할 수 있는 신경망
- 인접 행렬 + 특성 행렬을 입력으로 사용
- 합성곱 개념을 그래프에 확장 → 이웃 정보 집계
- 리드아웃으로 그래프 전체 벡터 생성
- SNS, 인용 네트워크, 3D Mesh, 분자 분석 등 다양한 응용