

Chapter 6. 이미지 분류를 위한 신경망 (Image Classification Neural Networks)

이미지 분류(image classification)는 주어진 이미지를 보고 그 이미지가 어떤 클래스(예: 고양이, 개, 자동차 등)에 속하는지를 판별하는 문제를 의미한다.

초기의 인공신경망(ANN)은 입력 이미지를 1차원으로 펼친 후 처리했기 때문에, 픽셀 간의 공간적 관계나 위치 정보를 제대로 반영하지 못했다.

이를 해결하기 위해 등장한 것이 합성곱 신경망(CNN, Convolutional Neural Network)이다.

CNN은 이미지의 공간적 구조를 유지한 채로 지역적 특징(local features)을 학습하며, 합성곱(convolution)과 풀링(pooling)을 통해 점점 추상적인 고차원 특징을 자동으로 추출한다.

이 장에서는 CNN의 발전 과정을 대표 모델들을 중심으로 살펴본다.

6.1.1 LeNet-5

등장 배경

LeNet-5는 1998년 Yann LeCun이 제안한 초기 합성곱 신경망으로, 딥러닝 시대의 기반이 된 모델이다.

당시에는 손글씨 숫자 인식(MNIST 데이터셋)을 목표로 설계되었으며, CNN 구조의 기본 틀을 처음으로 확립한 모델로 평가받는다.

기존의 완전연결 신경망(MLP)은 이미지의 모든 픽셀을 일렬로 입력받기 때문에 공간적 패턴(예: "이웃한 픽셀 간의 관계")을 무시하는 한계가 있었다.

LeNet-5는 이러한 한계를 극복하기 위해

합성곱층(Convolution Layer)과 풀링층(Pooling Layer)을 도입하여 공간 정보를 보존하면서 효율적으로 특징을 학습하는 방식을 제안했다.

구조

LeNet-5의 입력은 32×32 크기의 회색조(gray-scale) 이미지이다.

전체 구조는 다음과 같다.

입력(32×32)

- 합성곱층(6개의 5×5 필터, 출력 28×28)
- 평균 풀링층(Subsampling, 2×2 , 출력 14×14)
- 합성곱층(16개의 5×5 필터, 출력 10×10)
- 평균 풀링층(Subsampling, 2×2 , 출력 5×5)

→ 완전연결층(120→84→10)

→ 출력층(Softmax, 숫자 0~9 분류)

활성화 함수는 tanh 또는 sigmoid를 사용했으며,
가중치 공유(weight sharing)와 지역 수용영역(local receptive field)을 통해
연산량을 줄이면서도 특징 표현 능력을 높였다.

특징

1. 합성곱층은 이미지의 지역적 특징을 추출한다.
2. 풀링층은 공간 크기를 줄이고, 불변성(invariance)을 높인다.
3. 완전연결층은 최종적으로 분류를 담당한다.
4. 가중치 공유로 인해 파라미터 수가 급격히 감소하여 학습이 효율적이다.

의의

LeNet-5는 단순한 구조지만,
현재 대부분의 CNN 모델이 따르는 기본적인 설계 원리를 처음 제시했다.
'합성곱 → 풀링 → 완전연결층'으로 이어지는 계층적 구조는
이후 등장한 AlexNet, VGGNet, ResNet 등 모든 모델의 근간이 되었다.
현재는 간단한 학습용 예제(MNIST 등)에 자주 사용된다.

6.1.2 AlexNet

등장 배경

AlexNet은 2012년 ImageNet 대회(ILSVRC 2012)에서 압도적인 성능으로 우승한 모델이다.

당시 1위 모델보다 10% 이상 높은 정확도를 기록하며

"딥러닝 혁명"의 출발점이 되었다.

이전까지 CNN은 계산량이 많아 실무에서 활용하기 어려웠지만,

AlexNet은 GPU를 활용한 병렬 연산, 새로운 활성화 함수(ReLU),

드롭아웃(dropout), 데이터 증강(data augmentation) 등의 기법을 적용하여

실제 대규모 이미지 데이터에서도 CNN이 강력하게 작동할 수 있음을 입증했다.

구조

입력 이미지 크기는 $224 \times 224 \times 3$ 이며,

전체 모델은 5개의 합성곱층과 3개의 완전연결층으로 구성된다.

입력

→ Conv1 (11×11 커널, stride 4)

→ Max Pool

→ Conv2 (5×5 커널)

→ Max Pool

→ Conv3~5 (3×3 커널)

→ Max Pool

→ FC1 → Dropout

→ FC2 → Dropout

→ FC3 → Softmax

AlexNet은 두 개의 GPU에 모델을 나누어 학습했다.

각 GPU가 일부 필터를 처리하고, 중간 결과를 합쳐 다음 층으로 전달하는 방식이다.

주요 기술 및 특징

1. ReLU (Rectified Linear Unit)

기존 sigmoid, tanh보다 학습 속도가 빠르고,

기울기 소실(vanishing gradient) 문제를 완화했다.

CNN 학습을 실질적으로 가능하게 만든 핵심 요소이다.

2. Dropout

완전연결층에서 무작위로 뉴런을 꺼(overfitting 방지)

훈련 시 일부 연결을 제거하여 일반화 성능을 높임.

3. Data Augmentation

이미지 회전, 이동, 크롭, 색상 변화 등을 통해 데이터 다양성을 확보하여

모델이 특정 패턴에 과적합되는 것을 막았다.

4. GPU 병렬 처리

당시 대규모 모델을 학습할 수 있었던 이유는

GPU를 통한 병렬 연산 덕분이었다.

의의

AlexNet은 “딥러닝을 실전으로 끌어올린 첫 모델”로 평가받는다.

이전에는 사람이 직접 특징(feature)을 추출했지만,

AlexNet은 입력 이미지로부터 특징 추출과 분류를 **end-to-end 방식**으로 자동 학습했다.

즉, 사람이 설계하지 않아도 신경망이 스스로 유용한 특징을 학습하는 가능성을 증명했다.

이 모델 이후로 컴퓨터 비전 분야에서 CNN 기반 연구가 폭발적으로 증가했다.

6.1.3 VGGNet

등장 배경

VGGNet은 2014년 옥스퍼드 대학의 Visual Geometry Group(VGG)에서 발표한 모델로, “네트워크의 깊이가 깊을수록 성능이 향상된다”는 사실을 실험적으로 입증했다.

AlexNet 이후 더 복잡한 구조가 제안되었지만,

VGGNet은 오히려 구조를 단순화하여 “규칙적이고 일관된 형태의 깊은 CNN”을 만들었다.

구조

VGGNet은 3×3 크기의 합성곱 필터만을 반복적으로 사용한다.

커널 크기를 작게 하여 연산량을 줄이면서도,

연속적으로 여러 층을 쌓음으로써 넓은 수용영역(receptive field)을 확보한다.

대표적인 버전은 VGG16과 VGG19이다.

VGG16 기준 구조는 다음과 같다.

Conv(3×3) × 2 → MaxPool

Conv(3×3) × 2 → MaxPool

Conv(3×3) × 3 → MaxPool

Conv(3×3) × 3 → MaxPool

Conv(3×3) × 3 → MaxPool

FC(4096) → FC(4096) → Softmax(1000 classes)

즉, 모든 합성곱층이 동일한 크기의 커널을 사용하며,

단순하고 규칙적인 형태를 유지한다.

특징

1. 3×3 커널 반복 사용

큰 커널(예: 5×5)을 한 번 사용하는 대신,

3×3 커널을 여러 번 사용하여 더 많은 비선형 변환을 적용.

이는 파라미터 수를 줄이면서도 특징 표현력을 높인다.

2. 깊은 구조

층 수를 깊게 쌓으면 더 풍부한 표현이 가능해진다.

깊은 네트워크가 성능 향상으로 이어진다는 실험적 근거를 제시했다.

3. 단순하고 일관된 설계

모델 구조가 규칙적이어서 재현성이 높고,
전이학습(Transfer Learning)에도 유리하다.

4. 대규모 파라미터 수

약 1억 4천만 개 이상의 파라미터를 가지며,
메모리 및 계산 자원 소모가 크다.

의의

VGGNet은 이후 많은 연구의 기준 모델로 활용되었다.

단순한 구조 덕분에 실험적 비교에 유리하고,

전이학습의 기본 베이스라인으로도 자주 사용된다.

하지만 파라미터 수가 많아 학습 및 추론 비용이 큰 단점이 있다.

이로 인해 효율성을 개선한 GoogLeNet, ResNet 등의 등장 이어졌다.

6.1.4 GoogLeNet (Inception v1)

등장 배경

VGGNet은 깊이가 깊어질수록 성능이 향상된다는 점을 보여주었지만,

층이 깊어질수록 파라미터 수가 급격히 늘어나 계산량이 많아지고

기울기 소실(vanishing gradient) 문제가 다시 나타나는 단점이 있었다.

GoogLeNet은 이러한 문제를 해결하기 위해

“적은 연산량으로도 다양한 크기의 특징을 효과적으로 학습할 수 있는 구조”를 제안했다.

이 모델은 2014년 ImageNet 대회에서 우승하며, 효율적인 CNN 설계의 방향성을 제시했다.

구조

GoogLeNet의 핵심은 **Inception Module**이다.

Inception 모듈은 여러 크기의 합성곱 필터(1×1 , 3×3 , 5×5)를 병렬로 적용하고,

그 결과를 채널 방향으로 결합(concatenate)하는 구조이다.

이렇게 하면 다양한 크기의 특징을 동시에 학습할 수 있다.

예시 구조:

입력

→ [1×1 conv | 3×3 conv | 5×5 conv | 3×3 max pooling + 1×1 conv]

→ concatenate → 다음 inception 모듈

전체 GoogLeNet은 이러한 Inception 모듈을 여러 번 반복한 형태이며, 총 22개의 층으로 구성되어 있다.

주요 특징

1. Inception 모듈

서로 다른 크기의 커널을 병렬로 적용하여
작은 패턴(세부 특징)과 큰 패턴(전역 특징)을 동시에 학습할 수 있다.

2. 1×1 합성곱을 이용한 차원 축소

연산량을 줄이고, 비선형 변환을 추가하여 표현력을 높인다.
이는 "Network in Network" 개념을 차용한 것이다.

3. Auxiliary Classifier (보조 분류기)

중간 계층에 보조 분류기를 추가하여
기울기 소실을 방지하고 학습을 안정화한다.

4. 연산 효율성

깊은 네트워크임에도 불구하고
VGGNet보다 약 12배 적은 연산량으로 유사한 정확도를 달성했다.

5. 버전 확장성

이후 Inception v2, v3, v4, Inception-ResNet 등으로 발전하면서
Batch Normalization, Factorization, Residual 연결 등이 도입되었다.

의의

GoogLeNet은 CNN 구조의 효율성을 극대화한 모델이다.

다양한 크기의 필터를 동시에 사용해 풍부한 특징을 학습하면서도,

1×1 합성곱으로 연산량을 줄여 실용적인 깊은 신경망을 구현했다.

또한, 보조 분류기를 통한 안정적 학습이라는 새로운 아이디어를 제시했다.

이후 등장한 대부분의 대형 CNN 모델들은 Inception 구조의 개념을 변형하여 적용하였다.