

9주차 예습과제

🕒 과제 종류	예습과제
≡ 범위	자연어처리와 컴퓨터비전 심층학습 10장

Chapter 10. 비전 트랜스포머

ViT(Vision Transformer)


- 이미지 인식을 위한 딥러닝 모델
- 이미지를 자연어 처리 방식처럼 분류해 보려는 시도에 의해서 탄생함.
- CNN 모델의 합성곱 계층 방식을 사용하지 않고 트랜스포머 모델에서 사용되는 셀프 어텐션(**Self-Attention**)을 적용함.
 - 합성곱 모델(CNN): 지역적 특징 추출
 - ViT: 셀프 어텐션을 사용해 전체 이미지를 한번에 처리하는 방식
- 하지만 ViT 모델은 image patch가 왼쪽에서 오른쪽, 위에서 아래 방향으로 순차적으로 입력되어 2차원 구조의 image feature를 온전히 반영한다고 할 수 없다.

⇒ 물체의 크기나 해상도를 계층적으로 학습하는 **스윈 트랜스포머(Swin Transformer)**와 **CvT(Convolutional Vision Transformer)** 모델이 제안됨.

- **스윈 트랜스포머**: 로컬 윈도우(Local Window)를 활용하여 패치의 크기와 개수를 다양하게 구성하고, 상대적 위치 편향을 반영하여 이미지 특징을 계층적으로 학습시킨다.
- **CvT**: 기존 합성곱 과정을 ViT에 적용하여 저수준 특징(Low-level Feature)과 고수준 특징(High-level Feature)을 계층적으로 반영할 수 있다.

10.1 ViT

- ViT는 이미지 인식을 위해 Transformer 구조를 적용한 최초의 딥러닝 모델이며, 기존에는 CNN에 Transformer 모델의 self-attention 모듈만 적용한 모델이 많았음.



- BERT와의 비교:** ViT와 BERT는 모두 트랜스포머 모델 구조를 사용하지만, 입력 데이터를 구성하는 방식이 다르다.
 - BERT:** 문장보다 작은 단위의 토큰들이 순차적으로 입력된다.
 - ViT:** 격자로 나뉜 작은 단위의 **이미지 패치**가 순차적으로 입력된다.
- 입력 이미지 패치: ViT 모델에 사용되는 입력 이미지 패치는 왼쪽에서 오른쪽, 위에서 아래로 표현된 **시퀀셜(Sequential) 배열**을 가정한다.

10.2 합성곱 모델과 ViT 모델 비교

- 합성곱 신경망(CNN)과 ViT는 모두 이미지 특징을 잘 표현하는 임베딩을 만들고자 하는 목적은 같다.

1. 특징 추출 방식의 차이:

- **CNN:** 이미지 패치 중 일부만 선택하여 지역 특징을 추출하고, 이를 조합하여 전체 특징을 추론한다.
- **ViT:** 작은 패치들로 나눠 **셀프 어텐션**을 사용해 모든 이미지 패치 간의 상관관계를 학습하며, **모든 패치가 학습에 관여**하여 높은 수준의 이미지 표현을 제공한다.

2. 수용 영역(Receptive Field) 및 어텐션 거리(Attention Distance) 비교:

- **CNN:** **좁은 수용 영역**을 가지므로 전체 이미지 정보를 표현하는 데 수많은 계층이 필요하다.
- **ViT:** **어텐션 거리**를 계산하여 오직 한 개의 레이어로 전체 이미지 정보를 쉽게 표현할 수 있다.

3. ViT의 장점: ViT는 픽셀 단위가 아닌 패치 단위로 이미지를 처리하여 작은 모델로도 높은 성능을 얻을 수 있다.

4. ViT의 단점:

- 입력 이미지의 크기가 고정되어 있어 다른 크기의 이미지를 처리하려면 전처리가 필요하다.
- CNN이 이미지의 공간적 위치 정보를 고려하는 데 비해, ViT는 패치 간의 **상대적인 위치 정보만 고려**하므로 이미지 변환에 취약할 수 있다.

10.3 ViT의 귀납적 편향

귀납적 편향

딥러닝 모델의 일반화 성능 향상을 위한 모델의 가정(Assumption)을 의미한다.


예를 들어 이미지 데이터는 공간적 관계를 잘 표현하므로 지역적(Local) 편향을 가진 합성곱 신경망 모델이 많이 사용된다.

- 이미지 데이터 - 합성곱 신경망 모델

- 합성곱 신경망은 이미지를 작은 조각으로 나누어 조각별 특징을 추출하고, 이를 조합하여 전체 이미지 특징을 추론
- 지역적 특징을 강조하는 특성 덕분에 이미지 데이터에서 좋은 성능 발휘
- **시계열 데이터 - 순환 신경망 모델**
 - 시계열 데이터는 시간적 관계를 잘 표현하므로 시퀀셜(Sequential) 편향을 가진 순환 신경망 모델이 많이 사용됨
 - 순환 신경망은 이전 입력 상태를 기억하고 현재 입력과 결합하여 다음 상태를 예측함
 - 순차적 특성을 강조하여 시계열 데이터에서 좋은 성능을 보임
 - 하지만 특정 관계에 편향이 강할수록 다양한 관계를 표현하기 어려워 귀납적 편향이 약한 모델을 선호하게 됨
- **ViT 모델**
 - 입력 데이터의 다양한 쿼리(Query), 키(Key), 값(Value)의 임베딩 형태로 일반화된 관계를 학습하기 때문에 귀납적 편향이 거의 없고, 대용량 데이터에 대해 이미지 특징들의 관계를 잘 학습하는 모델로 알려짐
- **모델별 귀납적 편향:**
 - 합성곱 신경망(CNN): 이미지 데이터의 공간적 관계를 잘 표현하는 지역적(Local) 편향을 가진다. (작은 조각의 특징을 추출 후 조합)
 - 순환 신경망(RNN): 시계열 데이터의 시간적 관계를 잘 표현하는 순차적(Sequential) 편향을 가진다. (이전 상태를 기억하고 다음 상태 예측)
 - ViT: 입력 데이터의 다양한 관계를 임베딩 형태로 학습하므로 귀납적 편향이 거의 없다.
- 1. **편향의 영향:**
 - 귀납적 편향이 올바르다면 모델은 적은 데이터로 높은 일반화 성능을 보일 수 있다.
 - 너무 강한 편향은 다른 유형의 데이터나 관계를 표현하는 데 어려움을 초래할 수 있다.
- 2. **ViT의 특징:** ViT는 귀납적 편향이 거의 없기 때문에 **대용량 데이터**에 대해 이미지 특징들의 관계를 잘 학습하는 모델로 알려져 있다.

10.4 ViT 모델 구조

ViT 모델은 크게 **패치 임베딩(Patch Embedding)**과 **인코더(Encoder)** 계층으로 구성된다.



10.4.1 패치 임베딩 (Patch Embedding)

- **정의:** 패치 임베딩은 입력 이미지를 작은 패치로 분할하는 과정이다. 이를 위해 이미지 크기를 정방형 크기(예: 224x224)로 조절하는 전처리가 선행되어야 한다.
1. **패치 생성:** 이미지 크기를 조절한 후, 전체 이미지를 패치 크기로 분할하여 시퀀셜 배열을 만든다.
 - **커널 크기(Kernel Size):** 패치의 크기를 의미한다.
 - **간격(Stride):** 패치가 이동하는 폭을 의미한다.
 - 예시: 9x9 이미지, 커널 크기 3x3, 간격 3 → 총 9개(3x3)의 패치가 생성된다.
 2. **분류 토큰 추가:** 분할된 패치들은 왼쪽에서 오른쪽, 위에서 아래 순서로 나열되며, 배열 가장 왼쪽에 전체 이미지를 대표하는 **분류 토큰(CLS)**을 추가한다.

3. **위치 임베딩 및 정규화:** 위치 임베딩(Position Embedding)을 사용하여 패치의 위치 정보를 임베딩 벡터로 변환하고 기존 패치 벡터와 더한다. 마지막에 계층 정규화를 적용하여 패치 임베딩이 완성된다.

⇒ 이미지를 작은 패치로 나눠 처리하면 메모리 한계를 극복하고 더 큰 이미지를 처리할 수 있음.


10.4.2 인코더 계층 (Encoder Layer)

1. 입력된 패치 벡터를 다양한 쿼리(Query), 키(Key), 값(Value) 벡터로 변환 후 입력
2. Transformer의 Self-Attention 학습 과정과 동일하게 적용
마지막 레이어에서는 분류 토큰 벡터를 이용해 최종 분류 결과 도출
3. 시퀀셜 산출물(Sequential Output) 대신 전체 이미지 특징을 표현하는 분류 토큰 벡터만 사용하여 분류 문제를 해결한다.

10.6 Swin Transformer (스윈 트랜스포머)

- 2021년에 발표된 스윈 트랜스포머는 기존 ViT의 문제점(고정된 패치 크기, 고해상도 이미지 처리의 2차 계산 복잡도)을 극복하기 위해 등장했다.
- **주요 특징:**
 - **계층적 특징 맵**
 - 계층적(hierarchy) 특징 맵을 구성하여 이미지 분류, 객체 감지 등에서 강력한 성능을 발휘한다.
 - **1차 계산 복잡도**
 - 계산 복잡도를 2차(Quadratic)에서 1차(Linear)로 감소시켰다.
 - **시프트 윈도우(Shifted Window) 기술**
 - 입력 이미지를 패치로 분할하고 윈도우를 구성한 후, **윈도우 셀프 어텐션**을 계산한다. 이 방식은 패치를 겹쳐 효율성을 제공한다.
 - **계층적 어텐션**

- 계층마다 어텐션이 수행되는 패치의 크기와 개수를 계층적으로 적용하여 높은 해상도와 다양한 크기의 객체를 효율적으로 처리한다.



• ViT와의 차이점:


- ViT는 획일적인 패치 크기를 사용하지만, 스윈 트랜스포머는 계층별로 다양한 패치 크기를 사용한다.
- ViT는 공간 정보 보존이 어려우며, 스윈 트랜스포머는 로컬 윈도우와 시프트 윈도우 기술을 통해 패치의 위치를 유연하게 다룬다.
- ViT는 패치 수 증가 시 계산량이 2차로 증가하지만, 스윈 트랜스포머는 로컬 윈도우를 활용해 계산 복잡도를 1차로 낮춘다.

표 10.4 ViT와 스윈 트랜스포머 비교

	ViT	스윈 트랜스포머
분류 헤드	[CLS] 토큰 사용	각 토큰의 평균값 사용
로컬 윈도우 사용	X	O
상대적 위치 편향 사용	X	O
계층별 패치 크기	동일함	다양함

10.7 스윈 트랜스포머 모델 구조

- 스윈 트랜스포머 모델은 패치 파티션, 선형 임베딩, 스윈 트랜스포머 블록, 패치 병합 연산이 반복적으로 수행된다.




- Swin Transformer는 총 4개의 스테이지로 구성
- 각 스테이지는 서로 다른 해상도와 패치 크기를 사용하며, 선형 임베딩 → 스윈 블록 → 패치 병합의 과정을 반복한다.

10.7.1 패치 분할 및 패치 병합

패치 파티션 (Patch Partition)

- 입력 이미지를 작은 사각형 패치로 분할해 처리하는 방식
- 분할된 패치는 트랜스포머 계층의 입력으로 사용되며, 입력 이미지의 공간 정보를 보존하고 트랜스포머 계층에 대한 계산 효율성을 높임.




- 일반적인 이미지 텐서 $[C, H, W]$ 구조를 가짐.
- 이 구조에서 패치 파티션을 통해 로컬 윈도우를 추가한다.
 - 그림에서 M 은 로컬 윈도우의 크기를 의미
- 이 이미지 텐서의 차원이 $[3, 32, 32]$ 라면 패치의 가로와 세로는 4가 된다.

패치 병합(Patch Merging)

- 인접한 패치들의 정보를 저차원으로 축소하는 과정
- **모델의 매개변수를 줄이기 위해** 분할된 패치들을 순차적으로 합치면서 이미지의 전체 정보를 추출한다.
 - 패치 병합은 텐서 $[C, H, W]$ 를 $[2C, H/2, W/2]$ 로 재정렬한 후, 저차원 임베딩을 수행하여 매개변수 수를 줄인다.

10.7.2 스윈 트랜스포머 블록

- 스윈 트랜스포머 블록은 계층 정규화, **W-MSA**, **SW-MSA**, MLP 등으로 구성된다.




1. W-MSA (Window Multi-head Self-Attention):

- 로컬 윈도우를 사용하여 중첩되지 않게 나눈 각 윈도우에서 독립적으로 셀프 어텐션을 수행한다.
- 전체 입력에 대한 셀프 어텐션 비용을 **2차에서 1차 계산 복잡도로 줄인다**.
- 단점: 윈도우 내부의 지역적인 특징에만 어텐션을 수행한다.

2. SW-MSA (Shifted Window Multi-head Self-Attention):

- W-MSA의 단점을 보완하기 위해 윈도우를 가로/세로 방향으로 이동하여 **인접한 윈도우 간의 관계성**을 추출한다.
- 순환 시프트(Cyclic Shift)**와 **어텐션 마스크(Attention Mask)**를 사용하여 연산을 효율적으로 수행한다.
- 어텐션 마스크를 통해 불필요한 연산을 줄이고 효율적인 계산을 가능하게 한다.



10.8 CvT (Convolutional Vision Transformer)

CvT (Convolutional Vision Transformer)

- 합성곱 신경망(CNN)의 계층형 구조(Hierarchical Architecture)를 ViT에 적용한 모델이다.
- ViT 및 Swin과의 차이점:
 - ViT: 고정된 크기와 간격으로 패치를 학습하여 계층적 특징 학습이 어렵다.
 - Swin Transformer: 로컬 윈도우 크기를 다르게 사용하여 계층적 특징을 학습한다.
 - CvT: CNN의 계층적 구조를 적용하여 이미지의 지역 특징(Local Feature)과 전역 특징(Global Feature)을 모두 활용한다.

1. 장점


- CvT는 스윈 트랜스포머보다 더 적은 매개변수로 비슷한 성능을 달성한다.
- 기존 ViT보다 적은 계산량으로 높은 표현력을 제공한다.
- 합성곱 기반 구조로 이미지의 지역 구조를 더 잘 반영한다.

d. 실제 이미지 해석에 ViT 대비 더 유리한 구조를 가진다.

2. **계층적 특징 학습:** 저수준 계층에서 작은 단위의 특징(예: 입), 고수준 계층에서 전체적인 특징(예: 얼굴)을 표현하여 물체의 크기나 해상도를 더 잘 표현한다.

[동작 방식]

1. 입력 이미지에 합성곱 기반 패치 임베딩을 수행한다.
2. 각 계층에서 로컬 윈도우 단위의 어텐션으로 지역적 특성을 추출한다.
3. 상위 계층으로 갈수록 점점 더 넓은 범위의 정보를 반영하여 전역적 이해가 가능하다.
4. 최종적으로 전역 어텐션과 풀링을 통해 전체 이미지의 의미를 파악한다.




10.9 합성곱 토큰 임베딩

Convolutional Token Embedding

2D로 재구성된 토큰 맵에서 중첩 합성곱 연산을 통해 임베딩을 수행하는 방식

[동작 방식]

1. 기존 트랜스포머 모델은 이미지 패치를 펼쳐 벡터화한 후 직접 임베딩한다.
2. 반면, CvT 모델은 이미지의 2D 구조를 유지한 채 합성곱 연산을 통해 Query, Key, Value 임베딩을 수행한다.
3. 이렇게 얻어진 임베딩을 이용하여 셀프 어텐션을 계산하고 출력을 생성한다.



[장점]

- **공간 정보 보존:** 2D 구조를 유지하여 이미지의 공간적 관계를 더 잘 반영한다.
- **특징 추출 강화:** 중첩 합성곱을 통해 더 풍부한 시각 특징을 추출한다.
- **표현력 향상:** 단순 선형 임베딩보다 정교한 임베딩으로 성능을 향상시킨다.


10.10 어텐션에 대한 합성곱 토큰 임베딩

Convolutional Projection for Attention

2D로 재구성된 토큰 맵에 분리 가능한 합성곱 연산을 적용하여 성능을 유지하면서 계산 복잡도를 줄이는 임베딩 방식

[동작 방식]

1. 일반적인 Query, Key, Value 임베딩은 선형 변환으로 처리된다.
2. CvT 모델은 각 임베딩에 대해 작은 커널의 합성곱 연산을 적용한다.
3. **차원 수 축소(Squeeze)**를 통해 연산량을 줄이고, 정보는 압축하여 유지한다.



[장점]

- **계산 효율성 증가:** 연산량과 메모리 사용량을 줄여 효율적인 모델 구성이 가능하다.
- **특징 압축 유지:** 중요한 정보는 유지하면서도 모델을 경량화할 수 있다.
- **성능 저하 없이 경량화 달성:** 소형 모델에도 효과적인 어텐션을 구현할 수 있다.