

자연어 처리(NLP)의 핵심 전처리: 토큰화와 임베딩

05. 토큰화 (Tokenization)

자연어 처리는 비정형적인 언어 데이터를 기계가 이해할 수 있도록 구조화하는 과정이다. 토큰화는 텍스트를

5.1 단어 및 글자 토큰화

(1) 단어 토큰화

띄어쓰기나 구두점을 기준으로 텍스트를 단어 단위로 분리한다. 영어에 효과적이지만, 한국어는 조사 · 어미

(2) 글자 토큰화

문장을 글자 단위로 분리한다. 사전 크기가 작고 신조어에 강건하지만 문맥 이해가 어렵다.

5.2 형태소 토큰화

형태소는 의미를 가지는 최소 단위이다. 한국어는 교착어이므로 어근 · 조사 분석이 필요하다.

- 형태소 어휘 사전: 어근, 접사, 품사 정보를 포함한다.
- KoNLPy: 한국어 분석 패키지로 Okt, Komoran, Mecab, Kkma 등을 제공한다.
- NLTK: 영어 처리용 파이썬 라이브러리. 다양한 토큰나이저 제공.
- spaCy: 고성능 NLP 라이브러리로 품사 태깅, 구문 분석, 개체명 인식 등을 지원한다.

5.3 하위 단어 토큰화 (Subword Tokenization)

희귀 단어 문제를 완화하기 위해 단어를 작은 의미 단위로 분할한다.

- BPE(Byte Pair Encoding): 가장 자주 등장하는 문자 쌍을 병합하는 빈도 기반 알고리즘.
- WordPiece: 확률적 병합 방식을 사용하며, BERT 등에서 활용된다.

06. 임베딩 (Embedding)

토큰화된 단어를 수치 벡터로 변환하는 과정이다. 임베딩은 단어 의미를 수학적으로 표현한다.

6.1 TF - IDF (Term Frequency - Inverse Document Frequency)

문서 내 단어의 중요도를 측정하는 통계적 가중치 기법이다.

(1) 단어 빈도(TF): 특정 문서 내 단어의 등장 횟수.

(2) 문서 빈도(DF): 단어가 포함된 문서의 수.

(3) 역문서 빈도(IDF): $IDF(t, D) = \log(N / (1 + DF(t)))$

(4) TF - IDF: $TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D)$

자주 등장하는 단어의 중요도를 낮추고, 특정 문서에 특화된 단어의 가중치를 높인다.