

[자연어처리와 컴퓨터비전 심층학습]

6장

6장 임베딩

Word2Vec

- 정리
 - 분포 가설을 기반으로 단어 간의 유사성 측정
 - 분포 가설: 같은 문맥에서 함께 자주 나타나는 단어들은 서로 유사한 의미를 가질 가능성이 높다
 - 동시 발생 확률 분포를 이용해 단어 간의 유사성 측정
 - 가설을 통해 단어의 분산 표현 학습
 - 분산 표현: 단어를 고차원 벡터 공간에 매핑하여 단어의 의미를 담는 것
 - 유사한 문맥에서 등장하는 단어는 비슷한 벡터 공간상 위치를 갖게 됨
 - 빈도 기반의 벡터화 기법에서 단어의 의미 정보를 저장하지 못하는 한계 극복
 - 대량의 텍스트 데이터에서 단어 간 관계 파악
 - 벡터 공간상에서 유사한 단어를 군집화해 단어의 의미 정보를 효과적으로 표현

단어 벡터화

- 단어 벡터화의 방법
 - 희소 표현
 - 밀집 표현
- 희소 표현
 - 원-핫 인코딩, TF-IDF
 - 대부분의 벡터 요소가 0으로 표현되는 희소 표현 방법
 - 단어 사전의 크기가 커지면 벡터의 크기도 커짐 → 공간적 낭비 발생
 - 단어 간의 유사성 반영하지 못 함
 - 벡터 간의 유사성 계산에 많은 비용 발생

- 밀집 표현
 - Word2Vec
 - 단어를 고정된 크기의 실수 벡터로 표현
 - 단어의 사전 크기가 커지더라도 벡터의 크기가 커지지 않음
 - 벡터 공간상에서 단어 간의 거리를 효과적으로 계산
 - 벡터 대부분이 0이 아닌 실수로 이루어져 있어 효율적 공간 활용 가능

Word2Vec는 밀집 표현을 위해 CBoW와 Skip-gram이라는 두 가지 방법 사용

CBoW

- 정리
 - 주변에 있는 단어를 통해 중간에 있는 단어를 예측하는 방법
 - 용어 정리
 - 중심 단어: 예측해야 할 단어
 - 주변 단어: 예측에 사용되는 단어
 - 윈도우: 중심 단어를 맞추기 위해 몇 개의 주변 단어를 고려해야 할지 정하는 것
 - 슬라이딩 윈도우: 학습을 위해 윈도우를 이동해 가며 학습하는 것
 - 윈도우가 2일 때의 학습 데이터 구성모델 구조

입력 문장	학습 데이터
(세상의 재미있는 일들은)모두 밤에 일어난다	(재미있는, 일들은 세상의)
(세상의 재미있는 일들은 모두)밤에 일어난다	(세상의, 일들은, 모두 재미있는)
(세상의 재미있는 일들은 모두 밤에)일어난다	(세상의, 재미있는, 모두, 밤에 일들은)
세상의(재미있는 일들은 모두 밤에 일어난다)	(재미있는, 일들은, 밤에, 일어난다 모두)
세상의 재미있는(일들은 모두 밤에 일어난다)	(일들은, 모두, 일어난다 밤에)
세상의 재미있는 일들은(모두 밤에 일어난다)	(모두, 밤에 일어난다)

그림 6.4 CBoW의 학습 데이터 구성

- 모델 구조




그림 6.5 CBoW 모델 구조

1. 입력 단어의 원-핫 벡터를 입력값으로 받음
2. 입력 문장 내 모든 단어의 임베딩 벡터를 평균 내어 단어의 임베딩 벡터 예측
3. 입력 단어를 원-핫 벡터로 투사층에 입력
 - *투사층: 원-핫 벡터의 인덱스에 해당하는 임베딩 벡터 반환
4. 투사층을 통과해 E 크기의 임베딩 벡터로 변환
5. 입력된 세 단어의 임베딩 벡터들의 평균값 계산
6. 계산된 평균 벡터를 가중치 행결과 곱해 V 크기의 벡터를 얻음
7. 이 벡터에 소프트맥스 함수를 이용해 중심 단어 예측

Skip-gram

- 정리
 - 중심 단어를 입력으로 받아 주변 단어를 예측
 - 중심 단어를 기준으로 양쪽으로 윈도우 크기 만큼 단어들을 주변 단어로 삼아 훈련 데이터셋을 만들
 - 중심 단어와 각 주변 단어를 하나의 쌍으로 하여 모델 학습
 - 학습 데이터 구성

- CBoW는 하나의 윈도우에서 하나의 학습 데이터를 만들 때, Skip-gram은 중심 단어와 주변 단어를 하나의 쌍으로 하여 여러 학습 데이터가 만들어짐
 - 더 많은 학습 데이터셋 추출 가능
 - 일반적으로 CBoW보다 더 뛰어난 성능을 보임

입력 문장	학습 데이터
(세상의 재미있는 일들은)모두 밤에 일어난다	(세상의 재미있는), (세상의 일들은)
(세상의 재미있는 일들은 모두)밤에 일어난다	(재미있는 세상의), (재미있는 일들은), (재미있는 모두)
(세상의 재미있는 일들은 모두 밤에)일어난다	(일들은 세상의), (일들은 재미있는), (일들은 모두), (일들은 밤에)
세상의(재미있는 일들은 모두 밤에 일어난다)	(모두 재미있는), (모두 일들은), (모두 밤에), (모두 일어난다)
세상의 재미있는(일들은 모두 밤에 일어난다)	(밤에 일들은), (밤에 모두), (밤에 일어난다)
세상의 재미있는 일들은(모두 밤에 일어난다)	(일어난다 모두), (일어난다 밤에)

그림 6.6 Skip-gram의 학습 데이터 구성

• 모델 구조




그림 6.7 Skip-gram 모델 구조

1. 입력 단어의 원-핫 벡터를 투사층에 입력해 해당 단어의 임베딩 벡터를 가져옴
2. 입력 단어의 가중치와 W 가중치와의 곱셈을 통해 V 크기의 벡터를 얻음
3. 이 벡터에 소프트맥스 연산을 취해 주변 단어 예측

계층적 소프트맥스

- 정리
 - 출력층을 이진 트리 구조로 표현해 연산 수행
 - 자주 등장하는 단어일 수록 상위 노드에 배치
 - 빠른 속도와 효율성
- 구조




그림 6.8 계층적 소프트맥스 구조

추천해요 단어의 확률 = $0.43 \times 0.74 \times 0.27$
이 경우 학습 시 1, 2번 노드의 벡터만 최적화하면 됨

- 각 노드는 학습이 가능한 벡터를 가짐
- 입력값은 해당 노드의 벡터와 내적값을 계산한 후 시그모이드 함수를 통해 확률 계산
- 앞 노드: 가장 깊은 노드로 각 단어를 의미

네거티브 샘플링

- 정리
 - Word2Vec 모델에서 사용되는 확률적 샘플링 기법
 - 전체 단어 집합에서 일부 단어를 샘플링 하여 오답 단어로 사용
 - 입력 단어 쌍이 데이터로부터 추출된 단어 쌍인지, 네거티브 샘플링으로 생성된 단어 쌍인지 이진 분류

- 로지스틱 회귀 모델을 사용해 각 단어에 대한 가중치 학습 진행(추출할 단어의 확률 분포를 구하기 위함)

- 과정

$$P(w_i) = \frac{f(w_i)^{0.75}}{\sum_{j=0}^V f(w_j)^{0.75}}$$

각 단어가 추출될 확률 계산 수식

- 학습 원도 내 등장하지 않은 단어 n개 추출해 정답 단어와 함께 소프트맥스 연산 수행
- 추출할 단어 n은 일반적으로 5~20개 사용

- 훈련 데이터

입력 데이터	출력 데이터		입력 데이터	출력 데이터
재미있는	세상의	➡	재미있는. 세상의	1
재미있는	일들은		재미있는. 일들은	1
재미있는	모두		재미있는. 모두	1
			재미있는. 걸어가다	0
			재미있는. 주십시오	0
			재미있는. 미리	0
			재미있는. 안녕하세요	0

그림 6.9 네거티브 샘플링 모델의 훈련 데이터

- '재미있는' 중심 단어를 통해 세 쌍의 학습 데이터 추출
- 실제 데이터에서 추출된 단어 쌍은 1로, 네거티브 샘플링을 통해 추출된 가짜 단어 쌍은 0으로 레이블링
→ 다중 분류에서 이진 분류로 학습 목적이 바뀜

- 모델 구조




그림 6.10 소프트맥스 Word2Vec과 네거티브 샘플링 Word2Vec

- 입력 단어의 임베딩과 해당 단어가 맞는 여부를 나타내는 레이블(1또는 0)를 가져와 내적 연산 수행
- 내적 연산을 통해 얻은 값은 시그모이드 함수를 통해 확률값으로 변환
- 레이블이 1일 때 해당 확률값이 높아지도록/레이블이 0일 때 해당 확률값이 낮아지도록 모델의 가중치 최적화

fastText

- 정리
 - 텍스트 분류 및 텍스트 마이닝을 위한 알고리즘
 - 단어와 문장을 벡터로 변환하는 기술을 기반을 머신러닝 알고리즘이 텍스트 데이터를 분석하고 이해하는 데 사용됨
 - Word2Vec와 유사, 단어의 하위 단어를 고려해 더 높은 정확도와 성능을 제공
- 과정
 - 단어 벡터화를 위해 <>와 같은 특수 기호를 사용해 단어의 시작과 끝을 나타냄
 - 기호가 추가된 단어는 N-gram을 사용하여 하위 단어 집합으로 분해됨
 - ex. '서울특별시'를 바이어그램으로 분해하면 '서울', '울특', '특별', '별시'가 됨
 - 분해된 하위 단어 집합에는 나뉘지지 않은 자신도 포함
 - 하위 단어 벡터들이 단어의 벡터 표현을 구성하고, 이를 사용해 자연어 처리 작업 수행

입력 단어	< > 더하기	N-gram 분해	전체 단어 추가
서울특별시	<서울특별시>	<서울 서울특 울특별 특별시 별시>	<서울 서울특 울특별 특별시 별시> <서울특별시>

그림 6.11 fastText의 하위 단어 집합

1. 토큰의 끝에 < >를 붙여 토큰의 시작과 끝을 인식할 수 있게 함
2. N-gram을 사용해 분해된 토큰을 하위 단어 집합으로 분해
3. 분해된 하위 단어 집합에는 나뉘지지 않은 토큰 자체도 포함. 각 하위 단어는 고유한 벡터값을 가짐

순환 신경망(RNN)

- 정리
 - 연속적인 데이터를 처리하기 위해 개발된 인공 신경망의 한 종류
 - 이전에 처리한 데이터를 다음 단계에 활용, 현재 입력 데이터와 함께 모델 내부에서 과거 상태를 기억해 현재 상태 예측
 - 순서가 있는 연속적인 데이터를 처리하는 데 적합한 구조
 - 각 시점의 데이터가 이전 시점의 데이터가 독립적이지 않기 때문
 - 길이가 가변적이고 순서에 따른 의미가 있는 데이터를 사용하는 도메인에서 널리 사용됨
 - 시계열 데이터, 자연어 처리, 음성 인식 및 기타 시퀀스 데이터
- 과정
 - 연속형 데이터를 순서대로 입력받아 처리, 각 시점마다 은닉 상태의 형태로 저장
 - 셀(Cell): 각 시점의 데이터를 입력으로 받아 은닉 상태와 출력값을 계산하는 노드




그림 6.12 순환 신경망의 셀

- 은닉 상태

$$h_t = \sigma_h(h_{t-1}, x_t)$$

$$h_t = \sigma_h(W_{hh}h_{t-1} + W_{xh}x_t + b_h)$$

- 출력값

$$y_t = \sigma_y(h_t)$$

$$y_t = \sigma_y(W_{hy}h_t + b_y)$$

- 다양한 모델 구조 설계

- 일대다 구조

- 하나의 입력 시퀀스에 대해 여러 개의 출력값을 생성하는 순환 신경망 구조
ex. 문장을 입력으로 받아 각 단어의 품사를 출력
- 구현을 위해서 출력 시퀀스의 길이를 미리 알고 있어야 함
→ 입력 시퀀스를 처리하면서 시퀀스의 정보를 활용해 출력 시퀀스의 길이를 예측하는 모델을 함께 구현해야 함





그림 6.13 순환 신경망의 일대다 구조

○ 다대일 구조

- 여러 개의 입력 시퀀스에 대해 하나의 출력값을 생성하는 순환 신경망 구조
ex. 감성 분류 분야에서 문장을 입력받아 해당 문장의 감정(부정, 긍정)을 출력
- 자연어 추론에 적용 가능
*자연어 추론: 입력 시퀀스가 어떤 범주에 속하는지 문장 분류, 두 문장 간의 관계를 추론하는 것



○ 다대다 구조

- 입력 시퀀스와 출력 시퀀스의 길이가 여러 개인 경우 사용되는 순환 신경망 구조
- 입력 시퀀스와 출력 시퀀스의 길이가 다른 경우 존재
→ 길이를 맞추기 위해 패딩을 추가하거나 잘라내는 등의 전처리 과정 수행

○ 양방향 순환 신경망(BNN)

- 기본적인 순환 신경망에서 시간 방향을 양방향으로 처리할 수 있도록 고안된 방식

- 이전 시점의 은닉 상태와 이후 시점의 은닉 상태를 함께 이용
- 대부분의 연속형 데이터는 이전 시점 뿐만 아니라 이후 시점의 데이터와도 큰 상관관계를 가지기 때문에, 양방향 순환 신경망은 양방향적인 정보를 모두 고려하여 현재 시점의 출력값을 계산함




그림 6.16 양방향 순환 신경망 구조

○ 다중 순환 신경망

- 여러 개의 순환 신경망을 연결해 구성한 모델
- 각 순환 신경망이 서로 다른 정보를 처리하도록 설계
- 여러 개 층으로 구성된 RNN은 데이터의 다양한 특징을 추출할 수 있어 성능이 향상될 수 있음
- 층이 깊어질수록 더 복잡한 패턴을 학습할 수 있다는 장점이 있음
- 순환 신경망 층이 많아질수록 학습 시간이 오래 걸리고, 기울기 소실 문제가 발생할 가능성이 높다는 단점이 있음




그림 6.17 다중 순환 신경망 구조

장단기 메모리

- 정리
 - 기존 순환 신경망이 갖고 있던 기억력 부족과 기울기 소실 문제
 - 순환 신경망은 앞선 시점에서의 정보를 끊임없이 반영
 - 학습 데이터가 커질 수록 앞서 학습한 정보가 충분히 전달되지 않는 문제 발생
 - 장기 의존성 문제, 역전파 과정에서 기울기 소실 및 폭주 문제 발생 가능
 - 이를 메모리 셀과 게이트 구조를 도입해 해결한 것이 장단기 메모리
 - 셀 상태, 망각 게이트, 기억 게이트, 출력 게이트로 정보의 흐름 제어
 - 셀 상태: 정보를 저장하고 유지하는 메모리 역할, 출력/망각 게이트에 의해 제어
 - 망각 게이트: 이전 셀 상태에서 어떠한 정보를 삭제할지 결정
 - 입력 게이트: 새로운 정보를 어떤 부분에 추가할지 결정
 - 출력 게이트: 셀 상태의 정보 중 어떤 부분을 출력할지 결정
- 구조
 - 메모리 셀
 - 순환 신경망의 은닉 상태와 유사하게 현재 시점의 입력과 이전 시점의 은닉 상태를 기반으로 정보 계산, 저장
 - 순환 신경망의 은닉 상태와 달리 출력값 계산에 직접 사용되지 않음
 - 대신 망각/입력/출력 게이트를 통해 어떤 정보를 버림/기억/출력할지 결정하는 추가적인 연산 수행




그림 6.19 장단기 메모리 셀 상태

세 가지 게이트 모두 활성화 함수로 시그모이드 사용

1. 망각 게이트




그림 6.20 장단기 메모리의 망각 게이트

$$f_t = \sigma(W_x^{(f)}x_t + W_h^{(f)}h_{t-1} + b^{(f)})$$

현재 시점의 입력과 이전 시점의 은닉 상태를 입력으로 받음

→ 시그모이드 함수를 거친 값과 메모리 셀을 곱한 값으로 이전 시점의 메모리 셀 업데이트

→ 시그모이드 함수를 거치면 0과 1 사이 값이 출력되고, 이 값은 정보 유지/망각을 결정

2. 기억 게이트




그림 6.21 장단기 메모리의 기억 게이트

$$g_i = \tanh(W_x^{(g)}x_t + W_h^{(g)}h_{t-1} + b^{(g)})$$

$$i_i = \text{sigmoid}(W_x^{(i)}x_t + W_h^{(i)}h_{t-1} + b^{(i)})$$

현재 시점의 입력과 이전 시점의 은닉 상태를 입력으로 받음

→ 시그모이드 함수를 거친 값과 하이퍼볼릭 탄젠트 함수를 거친 값의 곱으로 새로운 기억 값 계산

→ 시그모이드 함수는 입력값의 중요도를 결정, 하이퍼볼릭 탄젠트 함수는 입력값을 -1과 1 사이 값으로 변환

⇒ 기억 게이트는 어떤 정보를 얼마나 추가할지 결정

3. 출력 게이트




그림 6.22 장단기 메모리의 출력 게이트

$$o_t = \sigma(W_x^{(o)}x_t + W_h^{(o)}h_{t-1} + b^{(o)})$$

현재 시점의 입력과 이전 시점의 은닉 상태, 그리고 새로 업데이트된 메모리 셀을 입력으로 받아 현재 시점의 출력값 계산

→ 어떤 정보를 출력할지 결정

합성곱 신경망(CNN)

- 정리
 - 컴퓨터비전 분야의 데이터를 분석하기 위해 사용되는 인공 신경망의 한 종류

- 합성곱 연산을 사용해 입력 데이터의 지역적인 특징을 추출하는 데 특화된 구조를 가짐
 - *합성곱 연산: 이미지의 특정 영역에서 입력값의 분포 또는 변화량을 계산해 출력 노드 생성
 - 특정 영역 안에서 연산을 수행하므로 **지역** 특징을 효과적으로 추출할 수 있음
- 이미지 데이터는 고정된 프레임 내의 객체들 위치와 형태가 자유분방하므로 여러 영역의 지역 특징을 조합해 입력 데이터의 전반적인 **전역** 특징을 파악할 수 있음
- 입력 데이터의 길에 상관없이 병렬처리가 가능
- 학습에 필요한 가중치를 줄여 깊은 신경망을 구성할 수 있음
 - 컴퓨터 비전뿐만 아니라 자연어 처리 작업에도 우수한 성능을 보임

합성곱 계층

- 정리
 - 입력 데이터와 필터를 합성곱해 출력 데이터를 생성하는 계층
 - 이미지나 음성 데이터와 같은 고차원 데이터를 처리하는 데 주로 사용됨
 - 필터를 사용해 데이터의 지역적인 패턴 인식 가능
 - 입력 데이터의 모든 위치에서 동일한 필터를 사용해 모델 매개변수 공유 → 과소적합 방지
- 구조
 - 필터
 - 입력 데이터에 사용되어 합성곱 연산을 수행
 - 커널, 윈도우로 불리기도 함
 - 일반적으로 3x3, 5x5와 같은 작은 크기의 정방형으로 구성
 - 패딩
 - 합성곱 연산 수행 후 특징 맵의 크기가 작아져 발생하는 문제 해결을 위해 입력 이미지나 입력으로 사용되는 특징 맵 가장자리에 특정 값을 덧붙이는 것
 - 가장자리에 덧붙이는 패딩 값은 0으로 할당하는데, 이를 제로 패딩이라고 함

- 패딩을 사용해 입력 데이터의 크기를 조정하고, 작은 크기의 필터로 이미지 전체에 대한 정보를 반영 가능
- 간격
 - 필터가 한번에 움직이는 크기
 - 간격의 크기를 조절함으로써 출력 데이터의 크기를 조절할 수 있음
 - 간격의 크기를 조절함으로써 입력 데이터의 공간적인 정보를 유지하거나 감소시킬 수 있음
- 채널
 - 입력 데이터와 필터가 3차원으로 구성되어 있을 때 같은 위치의 값끼리 연산되게 함
 - 입력 데이터의 공간 정보를 유지하면서 추출되는 특징 확장
 - 채널 개수는 합성곱 계층에서 설정되며, 모델의 구조나 목적에 따라 달라짐
 - 채널의 개수가 많아질 수록 학습할 수 있는 특징의 다양성이 증가해 표현력이 높아짐
- 팽창
 - 합성곱 연산을 수행할 때 입력 데이터에 더 넓은 범위의 영역을 고려할 수 있게 하는 기법
 - 필터와 입력 데이터 사이에 간격을 둠

활성화 맵

- 정리
 - 합성곱 계층의 특징 맵에 활성화 함수를 적용해 얻어진 출력값
 - 입력 이미지와 필터의 합성곱 연산을 통해 특징 맵을 추출하면 이 값에 비선형성을 추가하기 위해 활성화 함수 적용
 - 다음 계층의 입력값으로 사용되어 여러 번 반복해 신경망 구성
 - 입력 이미지에서 추출된 추상적인 특징 학습

풀링

- 정리
 - 특성 맵의 크기를 줄이는 연산

- 합성곱 계층 다음에 적용됨
- 특징 맵의 크기를 줄여 연산량을 감소시키고 입력 데이터의 정보를 압축하는 효과
- 종류
 - 최대값 풀링
 - 특정 크기의 필터 내 원소값 중 가장 큰 값을 선택해 특징 맵의 크기 감소시킴
 - 평균값 풀링
 - 필터 내 원소값의 평균값으로 특징 맵의 크기 감소시킴

완전 연결 계층

- 정리
 - 각 입력 노드가 모든 출력 노드와 연결된 상태 의미
 - 입력과 출력 간의 모든 가능한 관계 학습 가능
 - 출력 노드의 수를 조절할 수 있어 모델의 복잡성과 용량을 조절하는 데 사용됨