

[자연어처리와 컴퓨터비전 심층학습]

7장

BERT

정리

- 트랜스포머 기반 **양방향 인코더**를 사용하는 자연어 처리 모델
 - ***양방향 인코더**: 입력 시퀀스를 양쪽 방향에서 처리해 이전과 이후의 단어를 모두 참조하며 단어의 의미와 문맥 파악
- 이전 단어만 고려할 수 밖에 없는 기존의 언어 모델과 달리 이전과 이후의 단어를 모두 참조해 정확한 문맥 파악 가능
- 대규모 데이터를 사용해 사전 학습 → 전이 학습에 주로 활용
- 일부 또는 전체를 다른 작업에서 재사용해 적은 데이터로도 높은 정확도 달성
- 모델 학습 시간 단축
- BERT에서 사용되는 트랜스포머 모듈




그림 7.13 트랜스포머와 BERT 모델 비교

◦ 인코더

1. 입력 문장의 단어들을 임베딩

2. 각 단어의 의미 벡터화

3. 이를 순차적으로 처리해 문장 전체 의미 추출

사전 학습 방법

마스킹된 언어 모델링(MLM)과 다음 문장 예측 방법(NSP)을 사용

- 마스킹된 언어 모델링
 - 입력 문장에서 임의로 일부 단어를 마스킹하고 해당 단어를 예측하는 방식
- 다음 문장 예측
 - 두 개의 문장이 주어졌을 때, 두 번째 문장이 첫 번째 문장의 다음에 오는 문장인지 여부를 판단하는 작업
 - 두 문장 간의 관계를 학습하고, 문장 간의 의미적인 유사성을 파악

특수한 토큰들을 추가해 모델이 학습하고 추론하는 과정에서 필요한 정보를 제공

- [CLS] 토큰
 - 입력 문장의 시작 부분에 추가되는 토큰
 - 문장 분류 작업을 위한 정보 제공 → 입력 문장이 어떤 유형의 문장인지 미리 파악
- [SEP] 토큰
 - 입력 문장 내에서 두 개 이상의 문장을 구분하기 위해 사용되는 토큰
 - 입력 문장을 두 개의 독립적인 문장으로 인식하고, 각각의 문장에 대한 정보를 정확하게 파악
- [MASK] 토큰
 - 입력 문장 내에서 임의로 선택된 단어를 가리키는 특별한 토큰
 - 주어진 문장에서 일부 단어를 가린 후 모델의 학습과 예측에 활용
- BERT 모델의 입력 임베딩 구조, MLM과 NSP 손실 함수




그림 7.14 BERT 모델의 입력 임베딩과 손실 함수

BART

정리

- BERT의 인코더와 GPT의 디코더를 결합한 시퀀스-시퀀스 구조, 노이즈 제거 오토인코더로 사전 학습
 - BERT의 인코더: 일부 단어를 무작위로 마스킹해 처리, 마스킹된 단어를 맞추도록 학습
 - GPT의 디코더: 언어 모델을 이용해 문장의 이전 토큰들을 입력으로 받고 다음에 올 토큰을 맞추도록 학습

사전 학습 방법




그림 7.17 BART 노이즈 기법

• BERT 인코더

◦ 토큰 마스크

- 입력 문장의 일부 토큰을 마스크 토큰으로 치환
- 문장 내 어떤 단어가 중요한 역할을 하는지 학습 가능
- 입력 문장의 문맥을 이해하고 문장 내에서 중요한 정보를 추출하는 능력 향상

◦ 토큰 삭제

- 입력 문장의 일부 토큰을 치환하는 대신 삭제하는 방법
- 어떤 위치의 토큰이 삭제되었는지도 맞춰야 함
- 입력 문장에서 불필요한 정보나 중요하지 않은 정보를 자동으로 필터링해 처리할 수 있게 됨
- 모델의 학습과 예측 시간을 줄이고 모델의 일반화 성능 향상

◦ 문장 순열

- 마침표를 기준으로 문장을 나눈 뒤 문장의 순서를 섞는 방법
- 단어들이 어떻게 연결되어 있는지 더 잘 파악하게 됨
- 입력 문장이 다른 순서로 주어졌을 때에도 잘 처리하게 됨

◦ 문서 회전

- 임의의 토큰으로 문서가 시작하게 함 (문장 순열과 달리 문장의 순서는 유지)
- 문서의 시작점을 인식할 수 있도록 함

- 텍스트 채우기

- 몇 개의 토큰을 하나의 구간으로 묶고 일부 구간을 마스크 토큰으로 대체

미세 조정 기법




그림 7.18 BART 미세 조정 구조

- 문장 분류 작업
 - 입력 문장을 인코더와 디코더에 동일하게 입력
 - 디코더의 마지막 토큰 은닉 상태를 선형 분류기의 입력값으로 사용
- 토큰 분류 작업
 - 입력 문장을 인코더와 디코더에 동일하게 입력
 - 디코더의 각 시점별 마지막 은닉 상태를 토큰 분류기의 입력값으로 사용
 - 전체 입력과 디코더의 각 시점별 은닉 상태와의 어텐션 연산 수행
- 두 단계의 학습

1. 새로 추가된 트랜스포머 인코더의 가중치와 위치 임베딩, 첫 번째 인코더 층의 셀프 어텐션 입력 행렬 가중치만 학습
2. 모든 신경망의 가중치를 작은 반복으로 학습

ELECTRA

정리

- 입력을 마스킹하는 대신 생성자와 판별자를 사용해 사전 학습 수행
- 생성적 적대 신경망(GAN)과 유사한 방법으로 학습 수행
- 생성 모델을 통해 토큰을 생성하므로 보다 자연스러운 문장 생성 가능
- 모델의 매개변수가 적어 모델을 빠르게, 적은 메모리로 실행 가능

사전 학습 방법

- 생성자 모델
 - 트랜스포머 인코더 구조
 - 입력 문장의 일부 토큰을 마스크 처리하고 마스크 처리된 토큰이 원래 어떤 토큰이었는지 예측하며 학습
- 판별자 모델
 - 트랜스포머 인코더 구조
 - 각 입력 토큰이 원본 문장의 토큰인지 생성자 모델로 바뀐 모델인지 맞히며 학습
→ RTD(Replaced Token Detection)




그림 7.20 ELECTRA 모델 학습 방법

T5

정리

- 기존 자연어 처리 모델과 달리 입력과 출력을 모두 토큰 시퀀스로 처리하는 텍스트-텍스트 구조
- 입력과 출력의 형태를 자유롭게 다룰 수 있음
- 유연성과 확장성이 뛰어나 새로운 자연어 처리 작업에도 쉽게 적용할 수 있음
- 모델 학습 유형




그림 7.21 T5 모델 학습 유형

- CoLA 데이터세트: 문법적으로 허용 가능한 문장과 그렇지 않은 문장 구분
- STS-B 데이터세트: 문장 간 의미적 유사성 측정